



引用格式:王晨晖,袁颖,刘立申,等.基于主成分分析法优化广义回归神经网络的地震震级预测[J].科学技术与工程,2022,22(29):12733-12738.

Wang Chenhui, Yuan Ying, Liu Lishen, et al. Earthquake magnitude prediction based on generalized regression neural network optimized by principal component analysis[J]. Science Technology and Engineering, 2022, 22(29): 12733-12738.

天文学、地球科学

# 基于主成分分析法优化广义回归神经网络的地震震级预测

王晨晖<sup>1,2</sup>, 袁颖<sup>3,4\*</sup>, 刘立申<sup>1,2</sup>, 陈凯南<sup>1,2</sup>, 吴鹤帅<sup>1,2</sup>

(1. 河北红山巨厚沉积与地震灾害国家野外科学观测研究站, 邢台 054000; 2. 河北省地震局邢台地震监测中心站, 邢台 054000;  
3. 河北地质大学城市地质与工程学院, 石家庄 050031; 4. 河北省地下人工环境智慧开发与管控技术创新中心, 石家庄 050031)

**摘 要** 为科学有效预测地震震级,提出了基于广义回归神经网络(general regression neural network,GRNN)的地震震级预测模型。选取地震累计频度、累计释放能量、 $b$  值、异常地震群数、地震条带个数、活动周期、相关区震级等 7 个指标作为地震震级影响因子,利用主成分分析法(principal component analysis,PCA)对 7 个影响因子进行降维处理,以新生成的 4 个主成分作为模型输入变量,地震震级为输出变量,运用粒子群算法(particle swarm optimization,PSO)寻优得到 GRNN 模型最优光滑因子,最终建立基于 PCA-PSO-GRNN 的地震震级预测模型,利用建立的模型对训练样本进行回判检验,并对测试样本进行预测,并同传统反向传播(back propagation,BP)神经网络模型和单一 GRNN 模型预测结果进行对比,结果表明:PCA-PSO-GRNN 模型预测结果的平均误差为 5.17%,均方根误差为 0.100 0,决定系数为 0.986 8,均方相对误差为 0.007 3,平均绝对误差为 0.100 0,运行时间为 5.2 s,预测精度和运行效率均优于 BP 模型和单一 GRNN 模型。

**关键词** 主成分分析法; 粒子群算法; 广义回归神经网络; 地震震级

中图法分类号 P315;

文献标志码 A

## Earthquake Magnitude Prediction Based on Generalized Regression Neural Network Optimized by Principal Component Analysis

WANG Chen-hui<sup>1,2</sup>, YUAN Ying<sup>3,4\*</sup>, LIU Li-shen<sup>1,2</sup>, CHEN Kai-nan<sup>1,2</sup>, WU He-shuai<sup>1,2</sup>

(1. National Field Scientific Observation and Research Station for Huge Thick Sediments and Seismic Disasters in Hongshan, Hebei Province, Xingtai 054000, China; 2. Xingtai Central Seismic Station, Hebei Earthquake Agency, Xingtai 054000, China;  
3. School of Urban Geology and Engineering, Hebei Geologic University, Shijiazhuang 050031, China;  
4. Hebei Province Underground Artificial Environment Intelligent Development and Control Technology Innovation Center, Shijiazhuang 050031, China)

**[Abstract]** In order to predict earthquake magnitude scientifically and effectively, earthquake magnitude prediction model based on general regression neural network (GRNN) was proposed. Seven indexes such as earthquake cumulative frequency, cumulative released energy,  $b$  value, number of abnormal earthquake clusters, number of seismic bands, activity cycle and magnitude of relevant areas were selected as the influence factors of earthquake magnitude. Principal component analysis (PCA) was used to reduce the dimension of the seven influence factors, and the newly generated four principal components were used as the model input variables, the earthquake magnitude was taken as the output variable, the particle swarm optimization (PSO) algorithm was used to find the optimal smoothing factor of GRNN model, and finally the earthquake magnitude prediction model based on PCA-PSO-GRNN was established. The PCA-PSO-GRNN model was used to test the study samples and predict the test samples, the prediction results were compared with results of the back propagation (BP) neural network model and the single GRNN model. The results show that the average error of the

收稿日期: 2022-02-07; 修订日期: 2022-07-18

基金项目: 国家自然科学基金(41807231); 河北地质大学科技创新团队项目(KJCXTD-2021-08); 河北省地震科技星火项目(DZ2021110500001)

第一作者: 王晨晖(1992—),男,河北邢台人,硕士,工程师。研究方向:地震观测与预报。E-mail:caesar621@163.com。

\*通信作者: 袁颖(1976—),男,江西景德镇人,博士,教授。研究方向:工程抗震、地质灾害治理设计和结构损伤识别。E-mail:yuanyingson@163.com。

PCA-PSO-GRNN model is 5.17%, the root mean square error is 0.100 0, the coefficient of determination is 0.986 8, the mean square error is 0.007 3, the mean absolute error is 0.100 0, the running time is 5.2 s, and the prediction accuracy and operation efficiency were better than BP model and single GRNN model.

[**Keywords**] principal component analysis; particle swarm optimization algorithm; generalized regression neural network; earthquake magnitude

中国地震灾害频发,灾难性地震常常造成巨大的人员伤亡和财产损失,因此科学有效地进行地震预测对于防震减灾具有重要的指导意义<sup>[1-2]</sup>。

由于震级与其影响因子存在错综复杂的联系,普通的数学公式很难表达这种复杂的非线性关系,为此,许多专家学者进行了长期的探索。邓世广等<sup>[3]</sup>采用贝叶斯定理和综合概率法得到了年度地震危险概率预测结果。曹凤娟等<sup>[4]</sup>采用层次分析法建立了辽宁地区中强震预测指标体系进而计算各指标的权重。孙颖等<sup>[5]</sup>利用层次分析法求出桥梁震害各影响因子的重要度。以上传统研究方法均取得了良好的效果,但预测结果依赖专家经验,容易受主观因素影响。面对上述问题,神经网络等人工智能算法应运而生,并在地震震级预测领域得到了广泛的应用。徐程等<sup>[6]</sup>以滇西南地震数据为学习样本建立了反向传播(back propagation, BP)神经网络模型。蔡润等<sup>[7]</sup>将BP网络和SOM网络联合引入到地震震级的预测中。董晓娜等<sup>[8]</sup>采用《中国震例》作为数据源,通过初步整理分析和预处理,构建了较完备的震例研究样本集。但由于地震震级影响因子众多,单一地选用哪种评价方法,都会面临处理大量数据的问题,同时各影响因子与地震震级之间复杂的非线性关系导致模型学习效果不佳,预测精度较差。而BP神经网络易陷入局部最优,还需探索更为有效的科学方法。

广义回归神经网络(general regression neural network, GRNN)是经典的前馈式局部逼近神经网络,具有计算速度快、全局最优性等特点。粒子群优化算法(particle swarm optimization, PSO)是一种全新的参数寻优方法,它不仅可以辅助GRNN模型寻优,还可以调整模型结构,以此提高构建模型稳定性。基于此,现利用主成分分析法对7个影响因子进行降维处理,以新生成的4个主成分作为模型输入变量,地震震级为输出变量,运用粒子群算法寻优得到模型最优光滑因子,最终建立基于PCA-PSO-GRNN的地震震级预测模型,将建立的PCA-PSO-GRNN模型应用于光滑因子测试样本,实现地震震级预测。

## 1 基本原理

### 1.1 主成分分析法

主成分分析法是将原始变量重新线性组合成

新的互不相关的新变量,即主成分,新生成的主成分维度降低且保留原始变量的绝大部分信息<sup>[9-12]</sup>。具体过程为:设 $(X_1, X_2, \dots, X_n)$ 是总体 $X$ 的 $n$ 个样本,每个样本包括 $m$ 维变量,该矩阵可表示为

$$X_{m \times n} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix} \quad (1)$$

首先计算矩阵的协方差阵,求出其对应的相关系数阵。然后求出相关系数阵的特征值,且满足 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m \geq 0$ ,则第 $i$ 个主成分的贡献率为

$$\begin{cases} \lambda_i/P \\ P = \sum_{i=1}^m \lambda_i \\ i = 1, 2, \dots, m \end{cases} \quad (2)$$

前 $q$ 个主成分的累计贡献率为

$$\sum_{i=1}^q \lambda_i/P \quad (3)$$

当前 $q$ 个主成分累计贡献率达85%以上时,用这 $q$ 个主成分来代替初始的影响因子进行分析一般是满足要求的。

### 1.2 粒子群算法

PSO算法首先初始化 $n$ 个粒子,每个粒子代表GRNN一个光滑因子,粒子通过不断迭代寻求自身最优解 $P_{best}$ ,然后比较每个粒子的 $P_{best}$ ,寻优得到整体最优值 $G_{best}$ ,即粒子通过不断搜寻 $P_{best}$ 和 $G_{best}$ 并通过计算得到最新速度 $V$ 和位置 $Y$ (设有 $D$ 维空间),全部完成迭代,得到 $G_{best}$ 最优值<sup>[13-16]</sup>,即

$$V_{id}^{k+1} = \omega V_{id}^k + c_1 r_1 (P_{id}^k - Y_{id}^k) + c_2 r_2 (P_{gd}^k - Y_{id}^k) \quad (4)$$

$$Y_{id}^{k+1} = Y_{id}^k + V_{id}^{k+1} \quad (5)$$

式中: $d = 1, 2, \dots, D; i = 1, 2, \dots, n; k$ 为当前迭代次数; $\omega$ 为惯性权重; $V_{id}$ 为粒子的速度; $Y_{id}$ 为粒子的位置; $c_1, c_2$ 为加速度因子; $r_1, r_2$ 为 $[0, 1]$ 区间的随机数; $P_{id}, P_{gd}$ 分别为第 $i$ 个粒子的个体极值位置和群体极值位置。

### 1.3 广义回归神经网络

GRNN理论分析如下<sup>[17-21]</sup>,设随机变量 $x$ 和 $y$ 的观测值分别为 $X$ 和 $Y$ ,其联合概率密度函数为 $f(x, y)$ ,则 $Y$ 的预测输出 $\hat{Y}$ 为

$$\hat{Y} = E(y/X) = \frac{\int_{-\infty}^{+\infty} yf(X, y) dy}{\int_{-\infty}^{+\infty} f(X, y) dy} \quad (6)$$

假设  $f(x, y)$  服从正态分布, 则有

$$\hat{f}(X, y) = \frac{1}{n(2\pi)^{\frac{p+1}{2}}\sigma^{p+1}} \times \sum_{i=1}^n \exp\left[-\frac{(X-X_i)^T(X-X_i)}{2\sigma^2}\right] \times \exp\left[-\frac{(X-Y_i)^2}{2\sigma^2}\right] \quad (7)$$

式(7)中:  $X_i$  和  $Y_i$  分别为  $x$  和  $y$  的样本观测值;  $X$  为输入变量;  $n$  为样本数量;  $p$  为随机变量  $x$  的维度;  $\sigma$  为光滑因子。将  $\hat{f}(X, y)$  代替  $f(x, y)$  代入式(7)得

$$\hat{Y}(X) = \frac{\sum_{i=1}^n Y_i \exp\left[-\frac{(X-X_i)^T(X-X_i)}{2\sigma^2}\right]}{\sum_{i=1}^n \exp\left[-\frac{(X-X_i)^T(X-X_i)}{2\sigma^2}\right]} \quad (8)$$

GRNN 的网络结构由以下 4 个步骤实现。

**步骤 1** 输入层。该层神经元个数对应输入变量  $x_i$  即主成分个数。将 PCA 降维得到的 3 个主成分作为 GRNN 模型输入变量, 因此输入层神经元个数为 3。

**步骤 2** 模式层, 该层神经元个数等于训练样本的数量。每个神经元传递函数为

$$P_i = \exp\left[-\frac{(X-X_i)^T(X-X_i)}{2\sigma^2}\right], \quad i = 1, 2, \dots, n \quad (9)$$

**步骤 3** 求和层。该层由 2 种求和方式, 一种是算数求和  $S_D$ , 另一种是加权求和  $S_{Nj}$ , 传递函数分别为

$$S_D = \sum_{i=1}^n P_i \quad (10)$$

$$S_{Nj} = \sum_{i=1}^n y_{ij} P_i \quad (11)$$

式中:  $P_i$  为模式层第  $i$  个神经元的传递函数;  $y_{ij}$  为模式层第  $i$  个神经元与求和层第  $j$  个分子求和和神经元连接权值。

**步骤 4** 输出层。该层神经元个数只有 1 个, 即地震震级。将  $S_{Nj}$  与  $S_D$  相除, 得输出结果, 即

$$y_i = \frac{S_{Nj}}{S_D} \quad (12)$$

## 2 模型建立与预测

基于 PCA-PSO-GRNN 的地震震级预测模型构建流程图如图 1 所示, 具体步骤如下。

**步骤 1** 按式(13)对 7 个影响因子数据进行归一化处理。

$$X_i^* = (X_i - X_{\min}) / (X_{\max} - X_{\min}) \quad (13)$$

式(13)中:  $X_i$  和  $X_i^*$  分别对应第  $i$  个地震样本数据和其相应的归一化数据;  $X_{\min}$  和  $X_{\max}$  分别为各个影响因子的最小值和最大值。

**步骤 2** 对利用进行降维处理, 形成新的主成分, 以新生成的主成分作为输入变量。

**步骤 3** 利用 PSO 算法寻求 GRNN 最优光滑因子, 构建基于广义回归神经网络的粒子群算法优化的地震震级预测模型。

**步骤 4** 将建立的 PCA-PSO-GRNN 模型应用于地震震级测试样本, 实现地震震级预测。

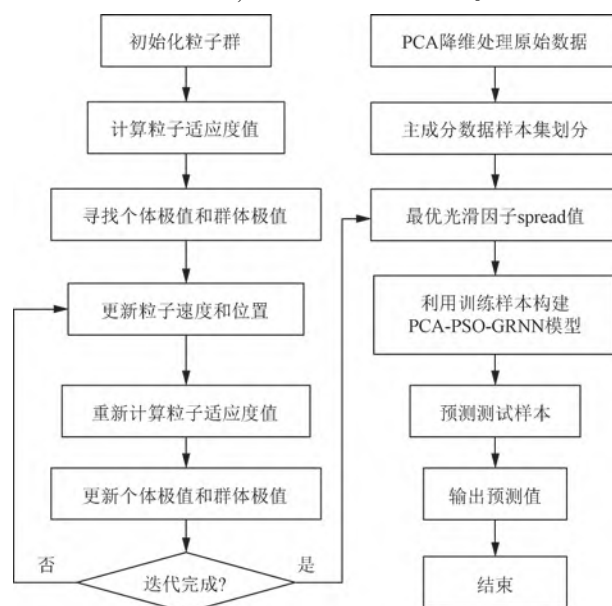


图 1 PCA-PSO-GRNN 模型流程图

Fig. 1 The flow chart of PCA-PSO-GRNN model

### 2.1 数据来源

通过查阅文献, 并结合前人经验选取文献[6]的地震数据作为研究样本, 地震样本部分原始数据如表 1 所示, 其中  $b$  值为震级和频度关系式中的比例系数。

### 2.2 主成分分析

利用 PCA 对 7 个地震震级影响因子进行分析, 得到归一化特征值, 各成分贡献率和累计贡献率如表 2 所示。从表 2 可以看出, 前 3 个主成分的累计贡献率为 88.348%, 基本能够反映原来 7 个变量所携带的信息。由成分得分系数矩阵可以得到 4 个主成分的表达式见式(14)。将提取出的 4 个线性无关的主成分代替原来的 7 个影响因子作为输入变量来建立 GRNN 模型, 有效降低了变量的维数, 提高了模型的运算效率。

表1 地震样本部分原始数据

Table 1 The partial original data of earthquake samples

序号	地震累积频度/次	累计释放能量/ $10^{12}$ J	$b$	异常地震群数量/个	地震条带数量/个	活动周期	相关区震级	震级
1	8	8.62	0.62	0	0	0	3.9	3.8
2	37	78.02	0.77	0.5	0.5	1	4.5	5.5
3	29	87.72	0.68	0	0.5	1	4.5	5.7
4	54	155	0.63	1	0.5	1	5.8	6.8
5	39	69.65	0.67	1	0	1	5.3	5.2
6	24	81.08	0.71	0	0	1	4.4	5.4
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
13	40	64.09	0.88	1	0	1	4.4	5.2
14	45	72.25	0.8	0	0	1	5.2	5.7
15	59	94.15	0.79	1	1	1	4.7	5.3
16	48	126.3	0.67	1	1	0	5.0	6.3
17	20	46.15	1.02	0	0	1	4.8	5.2

表2 主成分特征值、贡献率和累计贡献率

Table 2 Characteristic value, contribution rate and cumulative contribution rate

成分	特征值	贡献率/%	累计贡献率/%
$F_1$	3.606	51.508	51.508
$F_2$	1.223	17.466	68.975
$F_3$	0.887	12.668	81.642
$F_4$	0.469	6.706	88.348
$F_5$	0.419	5.983	94.331
$F_6$	0.293	4.182	98.513
$F_7$	0.104	1.487	100.000

$$\begin{cases} F_1 = 0.253x_1 + 0.247x_2 - 0.007x_3 + 0.203x_4 + \\ \quad 0.212x_5 + 0.14x_6 + 0.216x_7 \\ F_2 = 0.027x_1 - 0.219x_2 + 0.781x_3 + 0.179x_4 - \\ \quad 0.24x_5 + 0.178x_6 + 0.195x_7 \\ F_3 = -0.167x_1 + 0.146x_2 - 0.018x_3 - 0.493x_4 + \\ \quad 0.012x_5 + 0.907x_6 - 0.106x_7 \\ F_4 = 0.155x_1 - 0.186x_2 + 0.565x_3 - 0.437x_4 + \\ \quad 1.126x_5 - 0.239x_6 - 0.487x_7 \end{cases} \quad (14)$$

式(14)中: $x_1$ 为地震累积频度; $x_2$ 为累计释放能量; $x_3$ 为 $b$ 值; $x_4$ 为异常地震群数量; $x_5$ 为地震条带数量; $x_6$ 为活动周期; $x_7$ 为相关区震级。

根据前4个主成分的表达式,从而得到新生成的主成分数据样本,随机选出10个训练样本和7个预测样本。

### 2.3 预测结果分析

以新建立的4个主成分数据为整体样本,随机选取10组训练样本训练PCA-PSO-GRNN模型,并利用建好的模型对剩余7组测试样本进行测试,运用均方根误差(RMSE)、决定系数( $R^2$ )、均方相对误差(MSRE)和平均绝对误差(MAE)对模型训练样本回判结果和测试样本预测结果进行误差分析,计算公式如下。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (15)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2} \quad (16)$$

$$MSRE = \frac{1}{n} \sqrt{\sum_{i=1}^n \left[ \frac{(y_i - \hat{y}_i)}{y_i} \right]^2} \quad (17)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (18)$$

式中: $y_i$ 为第*i*个地震样本的地震震级实际值; $\hat{y}_i$ 为第*i*个地震样本的模型预测值; $\bar{y}_i$ 为所有测试样本震级实际值的平均值。

基于PCA-PSO-GRNN模型的地震震级训练样本和测试样本的误差分析结果如表3所示,训练样本回判结果和测试样本的预测结果如图2和图3所示。由表3和图2、图3可知,训练样本回判值与实际值基本一致,回判效果较好,平均误差率为5.84%,测试样本的预测值与实际值的平均误差率为5.17%,满足实际要求。PCA-PSO-GRNN模型训练样本和测试样本的误差分析如表4所示,由表4可以发现训练样本和测试样本的RMSE分别为0.114 0和0.100 0,表明模型训练精度较好。训练样本和测试样本的 $R^2$ 分别为0.983 4和0.986 8,表明模型的拟合程度较高。此外,测试样本的MSRE和MAE分别为0.007 3和0.100 0,均低于训练样本,表明模型预测精度表现良好。

为了更好地评判模型的有效性和泛化性能,将PCA提取的4个主成分作为各模型的输入变量分别建立BP模型和未经PSO优化的GRNN模型,并对测试样本分别进行预测,BP神经网络、单一GRNN网络与PCA-PSO-GRNN模型的模拟结果进行对比,预测结果误差分析如表5所示。可见,



PCA-PSO-GRNN 模型的预测效果显著优于其他 2 种模型,决定系数  $R^2$  分别较 BP 模型和标准 GRNN 模型提高 8.93% 和 21.56%,因此,采用 PCA 降维处理且利用 PSO 优化的 GRNN 模型具有更好的泛化性能和预测能力。

表 3 PCA-PSO-GRNN 模型误差分析表  
Table 3 Error analysis of PCA-PSO-GRNN

训练集				测试集			
样本编号	实测值	预测值	相对误差/%	样本编号	实测值	预测值	相对误差/%
1	3.8	3.9	7.69	11	4	4.1	7.32
2	5.5	5.3	9.43	12	5.5	5.4	5.56
3	5.7	5.8	5.17	13	5.2	5.1	3.92
4	6.8	6.7	2.99	14	5.7	5.8	6.90
5	5.2	5.3	7.55	15	5.3	5.4	3.70
6	5.4	5.3	3.77	16	6.3	6.2	4.84
7	7	6.9	2.90	17	5.2	5.1	3.92
8	5	5.1	3.92				
9	4.8	4.7	6.38				
10	5.9	5.8	8.62				




图 2 训练样本回判值与实际值对比  
Fig. 2 The comparison between return value and actual value of study samples




图 3 测试样本预测值与实际值对比  
Fig. 3 The comparison between prediction value and actual value of test samples

表 4 训练样本与测试样本误差分析

指标	RMSE	$R^2$	MSRE	MAE
训练样本	0.114 0	0.983 4	0.006 8	0.110 0
测试样本	0.100 0	0.986 8	0.007 3	0.100 0

表 5 3 种模型误差分析

Table 5 Error analysis of three models

模型	RMSE	$R^2$	MSRE	MAE	运行时间/s
BP	0.267 3	0.905 9	0.019 4	0.257 1	15.7
GRNN	0.378 0	0.811 8	0.027 4	0.371 4	14.9
PCA-PSO-GRNN	0.100 0	0.986 8	0.007 3	0.100 0	5.2

### 3 结论与分析

(1) 采用 PCA 对影响地震震级的 7 个影响因子进行降维处理,模型输入维度由 7 维降至 4 维,优化了模型结构,提高了模型运行效率。

(2) 利用 PSO 寻优得到最优光滑因子,通过对模型的回判结果和预测结果进行误差分析,得到训练样本的 RMSE、 $R^2$ 、MSRE 和 MAE 分别为 0.114 0、0.983 4、0.006 8 和 0.110 0,测试样本的 RMSE、 $R^2$ 、MSRE 和 MAE 分别为 0.100 0、0.986 8、0.007 3 和 0.100 0。

(3) PCA-PSO-GRNN 预测精度和运行效率均优于 BP 模型和单一 GRNN 模型,可以为地震震级预测提供参考。

### 参 考 文 献

- [1] 马广庆, 王晓山, 冯向东, 等. 张渤地震带现今形变特征研究[J]. 科学技术与工程, 2021, 21(30): 12814-12821.  
Ma Guangqing, Wang Xiaoshan, Feng Xiangdong, et al. Study on deformation characteristics of Zhangjiakou-Bohai seismic belt based on GNSS data and focal mechanism solution[J]. Science Technology and Engineering, 2021, 21(30): 12814-12821.
- [2] 李承玥, 王宪杰, 胡彪, 等. 基于地震损伤次生火灾概率研究[J]. 科学技术与工程, 2021, 21(18): 7711-7716.  
Li Chengyue, Wang Xianjie, Hu Biao, et al. Study on the probability of secondary fire based on earthquake damage[J]. Science Technology and Engineering, 2021, 21(18): 7711-7716.
- [3] 邓世广, 周龙泉, 马亚伟, 等. 基于贝叶斯定理的地震危险性概率预测研究[J]. 中国地震, 2019, 35(1): 1-13.  
Deng Shiguang, Zhou Longquan, Ma Yawei, et al. Research on probability prediction of earthquake risk based on Bayesian theorem[J]. Earthquake in China, 2019, 35(1): 1-13.
- [4] 曹凤娟, 焦明若. 基于层次分析的辽宁地区中强震预测指标体系及效能评估[J]. 中国地震, 2012, 28(4): 415-424.  
Cao Fengjuan, Jiao Mingruo. Efficiency evaluation of prediction indicators for medium-strong earthquakes in the Liaoning area based on analytic hierarchy[J]. Earthquake in China, 2012, 28(4): 415-424.
- [5] 孙颖, 邢文杰, 游福科. 基于模糊层次分析法的公路梁式桥地震震害预测研究[J]. 福州大学学报(自然科学版), 2013, 41(4): 776-781, 800.  
Sun Ying, Xing Wenjie, You Fuke. The research on the earthquake damage prediction of highway girder bridges based on fuzzy analytical hierarchy approach[J]. Journal of Fuzhou University (Natural Science Edition), 2013, 41(4): 776-781, 800.
- [6] 徐程, 邹金慧. BP 神经网络在地震预测中的应用研究[J]. 自

- 动化仪表, 2012, 33(6): 12-14, 17.
- Xu Cheng, Zou Jinhui. Research and application of BP neural network in earthquake prediction[J]. Process Automation Instrumentation, 2012, 33(6): 12-14, 17.
- [7] 蔡润, 武震, 云欢, 等. 基于BP和SOM神经网络相结合的地震预测研究[J]. 四川大学学报(自然科学版), 2018, 55(2): 307-315.
- Cai Run, Wu Zhen, Yun Huan, et al. Research on earthquake prediction based on BP and SOM neural network[J]. Journal of Sichuan University (Natural Science Edition), 2018, 55(2): 307-315.
- [8] 董晓娜, 苏道磊, 李希亮, 等. 基于粗糙集的BP神经网络在震例中的应用研究[J]. 地震研究, 2012, 35(2): 251-259, 296.
- Dong Xiaona, Su Daolei, Li Xiliang, et al. Application of BP neural network based on rough set in the earthquake case[J]. Journal of Seismological Research, 2012, 35(2): 251-259, 296.
- [9] 李桥, 巨能攀, 黄健, 等. 基于主成分分析的PSO-ELM-Adaboost算法耦合模型在极震区泥石流源点储量计算中的应用[J]. 科学技术与工程, 2020, 20(15): 5961-5970.
- Li Qiao, Ju Nengpan, Huang Jian, et al. The calculation method for predicting dynamic reserve in meizoseismic area based on a coupling model between PSO-ELM and Adaboost by PCA[J]. Science Technology and Engineering, 2020, 20(15): 5961-5970.
- [10] 何坚强, 侯建成, 汪志成. 基于主成分分析和区域增长的结构光中心线提取[J]. 科学技术与工程, 2020, 20(12): 4793-4797.
- He Jianqiang, Hou Jiancheng, Wang Zhicheng. Structured light center line extraction based on principal component analysis and region growth[J]. Science Technology and Engineering, 2020, 20(12): 4793-4797.
- [11] 张研, 邝贺伟. 基于主成分分析-相关向量机的高速公路路基沉降量预测[J]. 科学技术与工程, 2020, 20(1): 312-319.
- Zhang Yan, Kuang Hewei. Settlement prediction of highway subgrade based on principal component analysis-relevance vector machine[J]. Science Technology and Engineering, 2020, 20(1): 312-319.
- [12] 韩松, 徐林森. 基于主成分分析和支持向量机分类模型的滚动轴承故障诊断[J]. 科学技术与工程, 2021, 21(8): 3153-3158.
- Han Song, Xu Linsen. Research on fault diagnosis of rolling bearing based on classification model of PCA and SVM[J]. Science Technology and Engineering, 2021, 21(8): 3153-3158.
- [13] 闫德超, 马超, 杨坤, 等. 基于工况与粒子群优化的增程汽车能量管理策略开发[J]. 科学技术与工程, 2021, 21(26): 11396-11404.
- Yan Dechao, Ma Chao, Yang Kun, et al. Development and optimization of energy management strategy for extended program electric vehicle based on condition analysis and adaptive weighted particle swarm optimization[J]. Science Technology and Engineering, 2021, 21(26): 11396-11404.
- [14] 蒋华伟, 郭陶, 杨震. 基于改进粒子群优化-反向传播神经网络算法的小麦储藏品质预测模型[J]. 科学技术与工程, 2021, 21(21): 8951-8956.
- Jiang Huawei, Guo Tao, Yang Zhen. Research on prediction model of wheat storage quality based on IPSO-BP neural network[J]. Science Technology and Engineering, 2021, 21(21): 8951-8956.
- [15] 姜吉光, 盛宇博, 常川, 等. 基于粒子群优化算法-支持向量回归算法的氨氮传感器温度补偿[J]. 科学技术与工程, 2021, 21(21): 8983-8988.
- Jiang Jiguang, Sheng Yubo, Chang Chuan, et al. Research on temperature compensation of ammonia nitrogen sensor based on PSO-SVR algorithm[J]. Science Technology and Engineering, 2021, 21(21): 8983-8988.
- [16] 张丽霞, 刘家琪, 潘福全, 等. 基于改进粒子群算法的轮胎模型参数两级辨识[J]. 科学技术与工程, 2021, 21(16): 6876-6881.
- Zhang Lixia, Liu Jiaqi, Pan Fuquan, et al. Two-stage parameter identification of tire model based on improved particle swarm optimization algorithm[J]. Science Technology and Engineering, 2021, 21(16): 6876-6881.
- [17] 景彤梅, 齐咏生, 刘利强, 等. 基于KECA-GRNN的风电机组齿轮箱状态监测与健康评估[J]. 太阳能学报, 2021, 42(6): 400-408.
- Jing Tongmei, Qi Yongsheng, Liu Liqiang, et al. Condition monitoring and health assessment of wind turbine gearbox based on KECA-GRNN[J]. Acta Energetica Solaris Sinica, 2021, 42(6): 400-408.
- [18] 杨娟, 杨占刚. 基于GRNN算法的飞机用电设备非侵入式负荷监测方法[J]. 航空学报, 2021, 42(3): 403-413.
- Yang Juan, Yang Zhangang. Non-intrusive load monitoring method for aircraft electrical equipment based on GRNN algorithm[J]. Acta Aeronautica et Astronautica Sinica, 2021, 42(3): 403-413.
- [19] 张飞, 张志伟, 万乐斐, 等. 基于EEMD-GRNN方法的光伏电站短期出力预测[J]. 太阳能学报, 2020, 41(12): 103-109.
- Zhang Fei, Zhang Zhiwei, Wan Lefei, et al. Short-term output prediction of photovoltaic power station based on EEMD-GRNN method[J]. Acta Energetica Solaris Sinica, 2020, 41(12): 103-109.
- [20] 李春艳, 李庚鹏, 刘继红, 等. 基于GRNN的光谱共焦位移测量方法分析与研究[J]. 光子学报, 2021, 35(1): 1-9.
- Li Chunyan, Li Gengpeng, Liu Jihong, et al. Analysis and research on spectral confocal displacement measurement method based on GRNN[J]. Acta Photonica Sinica, 2021, 35(1): 1-9.
- [21] 王继选, 胡润志, 管一, 等. 基于RFOA优化GRNN的水电机组振动预测[J]. 振动与冲击, 2021, 40(21): 120-126.
- Wang Jixuan, Hu Runzhi, Guan Yi, et al. Vibration prediction of hydropower unit based on RFOA-GRNN[J]. Journal of Vibration and Shock, 2021, 40(21): 120-126.